

TECH CHALLENGE - FASE 1

Sistema Inteligente de Suporte ao Diagnóstico Médico

Classificação de câncer de mama com Machine Learning e diagnóstico complementar por CNN

Campo	Informação
Curso	Pós IA para DEVs / FIAP
Fase	Fase 1
Tema	IA aplicada ao apoio diagnóstico médico
Integrantes	Diogo da Silva Souza
Repositório GitHub	https://github.com/Diogosouza3101/tech-challenge-FIAP-fase1-diagnostico-medico
Vídeo de demonstração	https://www.youtube.com/watch?v=8CTsa0KDnWw

Maio/2026

Resumo Executivo

Este relatório apresenta a solução desenvolvida para o Tech Challenge da Fase 1, cujo objetivo foi construir uma base inicial de Inteligência Artificial para apoio ao diagnóstico médico. A solução principal utiliza dados estruturados do dataset Breast Cancer Wisconsin para classificar exames como benignos ou malignos por meio de modelos de Machine Learning. Como entrega adicional, foi desenvolvido um experimento com imagens de mamografia usando rede neural convolucional baseada em EfficientNetB0.

No modelo principal, a Regressão Logística foi selecionada após comparação com Árvore de Decisão e Random Forest. No conjunto de teste, o modelo alcançou accuracy de 96,51%, recall de 96,30% e F1-score de 97,20%. No Extra com CNN, foram testadas variações da EfficientNetB0 com class_weight, ajuste de threshold e fine-tuning. A melhor alternativa para triagem foi o modelo inicial com class_weight, por apresentar o maior recall para a classe maligna, ainda que com desempenho global inferior ao modelo estruturado.

A proposta deve ser compreendida como ferramenta de apoio à triagem e à tomada de decisão clínica. O modelo não substitui a avaliação médica, devendo ser validado com dados reais e processos de governança antes de qualquer aplicação operacional.

Sumário

1. Introdução
2. Objetivo do projeto
3. Base de dados estruturada
4. Análise exploratória dos dados
5. Pré-processamento dos dados
6. Modelagem preditiva
7. Resultados do modelo principal
8. Interpretabilidade do modelo
9. Extra: diagnóstico com imagens por CNN
10. Organização do projeto e reprodutibilidade
11. Discussão crítica
12. Conclusão
13. Referências e links

1. Introdução

Hospitais e equipes clínicas lidam com um volume crescente de exames, imagens e informações assistenciais. Nesse contexto, soluções baseadas em Inteligência Artificial podem apoiar a análise inicial dos dados, acelerar etapas de triagem e destacar informações relevantes para o profissional de saúde.

Este projeto desenvolve uma solução inicial para suporte ao diagnóstico de câncer de mama, utilizando duas frentes complementares: uma abordagem principal com Machine Learning em dados estruturados e uma abordagem extra com Visão Computacional aplicada a imagens de mamografia. A classificação proposta distingue casos benignos e malignos, sempre considerando que a decisão final deve permanecer sob responsabilidade médica.

2. Objetivo do projeto

O objetivo deste trabalho é construir e avaliar modelos preditivos capazes de apoiar a classificação de exames médicos em benignos ou malignos, aplicando fundamentos de IA, Machine Learning, pré-processamento de dados, avaliação de métricas e interpretabilidade.

- Explorar e preparar uma base médica pública de dados estruturados.
- Treinar e comparar dois ou mais modelos de classificação.
- Avaliar o desempenho com métricas adequadas ao contexto médico.
- Interpretar os resultados por coeficientes, feature importance e SHAP.
- Desenvolver uma entrega extra com CNN para classificação de imagens de mamografia.
- Organizar o projeto para execução reproduzível via GitHub, README, requirements.txt e Dockerfile.

3. Base de dados estruturada

A base principal utilizada foi a Breast Cancer Wisconsin, disponível no scikit-learn e originalmente derivada de dados clínicos de câncer de mama. A base contém atributos numéricos extraídos de exames, como raio, textura, perímetro, área, suavidade, concavidade e pontos côncavos, incluindo suas versões médias, erros e piores valores.

A variável alvo foi representada da seguinte forma: 0 = maligno e 1 = benigno. A base final do notebook ficou com 569 registros e 32 colunas, sendo 30 variáveis explicativas, a variável target e uma coluna auxiliar de diagnóstico textual.

Classe	Quantidade	Percentual
Benigno	357	62,74%
Maligno	212	37,26%
Total	569	100,00%

4. Análise exploratória dos dados

A análise exploratória indicou que a base não possui valores nulos nas variáveis utilizadas, o que eliminou a necessidade de imputação. A distribuição das classes apresentou predominância de casos benignos, mas sem desbalanceamento extremo, permitindo o uso inicial das métricas accuracy, recall e F1-score.




Figura 1 - Distribuição dos diagnósticos na base estruturada.

A matriz de correlação mostrou forte associação entre alguns atributos, principalmente variáveis relacionadas a raio, perímetro, área, concavidade e pontos côncavos. Essa correlação sugere possível redundância entre atributos, mas os dados foram mantidos na etapa inicial porque os algoritmos avaliados conseguem lidar com esse comportamento e porque a interpretabilidade posterior permite identificar variáveis mais relevantes.




Figura 2 - Matriz de correlação das variáveis estruturadas.




Figura 3 - Correlação das variáveis com a variável target.

5. Pré-processamento dos dados

O pré-processamento consistiu na separação entre variáveis explicativas e variável alvo, divisão estratificada da base em treino, validação e teste, e padronização das variáveis numéricas. A padronização foi aplicada para colocar os atributos em escala comparável, etapa especialmente relevante para modelos sensíveis à magnitude das variáveis, como a Regressão Logística.

Conjunto	Quantidade de registros	Observação
Treino	397	Usado para ajuste dos modelos
Validação	86	Usado para comparação inicial
Teste	86	Usado para avaliação final

- Variáveis explicativas: 30 atributos numéricos do exame.
- Variável alvo: target, com 0 para maligno e 1 para benigno.

- Divisão com `random_state=42` e `stratify` para preservar a proporção das classes.
- Padronização com `StandardScaler` ajustado somente no conjunto de treino.

6. Modelagem preditiva

Foram treinados três modelos de classificação: Regressão Logística, Árvore de Decisão e Random Forest. A comparação inicial foi feita no conjunto de validação usando accuracy, recall e F1-score. Em contexto médico, o recall é uma métrica crítica, pois representa a capacidade do modelo de identificar corretamente os casos positivos. Como neste notebook a classe 1 representa benigno, a interpretação clínica das métricas deve ser complementada pela matriz de confusão e pelo classification report das duas classes.

Modelo	Accuracy validação	Recall validação	F1-score validação
Regressão Logística	1,0000	1,0000	1,0000
Random Forest	0,9651	0,9630	0,9720
Árvore de Decisão	0,9535	0,9444	0,9623

A Regressão Logística apresentou o melhor desempenho no conjunto de validação e foi selecionada para a avaliação final no conjunto de teste. Além do desempenho, esse modelo tem vantagem de maior interpretabilidade por meio da análise dos coeficientes.

7. Resultados do modelo principal

No conjunto de teste, a Regressão Logística manteve desempenho elevado, indicando boa capacidade de generalização para dados não vistos. O modelo apresentou apenas 3 erros de classificação em 86 registros avaliados.

Métrica	Resultado no teste
Accuracy	0,9651 / 96,51%
Recall	0,9630 / 96,30%
F1-score	0,9720 / 97,20%

Classe	Precision	Recall	F1-score	Support
Maligno (0)	0,94	0,97	0,95	32
Benigno (1)	0,98	0,96	0,97	54
Accuracy	-	-	0,97	86
Macro avg	0,96	0,97	0,96	86
Weighted avg	0,97	0,97	0,97	86




Figura 4 - Matriz de confusão da Regressão Logística no conjunto de teste.

8. Interpretabilidade do modelo

A interpretabilidade foi avaliada por três frentes: coeficientes da Regressão Logística, importância de variáveis do Random Forest e análise SHAP. Essa etapa é relevante porque modelos aplicados à saúde precisam de transparência e rastreabilidade, principalmente quando usados como apoio à decisão.

8.1 Coeficientes da Regressão Logística

Na Regressão Logística, coeficientes com maior valor absoluto indicam maior influência sobre a classificação. Coeficientes positivos favorecem a classe 1, enquanto coeficientes negativos favorecem a classe 0.

Variável	Coeficiente	Coef. absoluto
worst symmetry	-1,1022	1,1022
radius error	-1,0944	1,0944
worst texture	-1,0773	1,0773
worst area	-0,9277	0,9277
area error	-0,9211	0,9211
worst radius	-0,9113	0,9113
worst concavity	-0,8843	0,8843
worst smoothness	-0,8012	0,8012
worst concave points	-0,7804	0,7804
mean compactness	0,7343	0,7343




Figura 5 - Top 10 variáveis mais influentes na Regressão Logística.

8.2 Feature importance com Random Forest

Como visão complementar, a importância das variáveis foi avaliada com Random Forest. As variáveis mais importantes se concentraram em atributos relacionados a pontos côncavos, área, raio, perímetro e concavidade, coerentes com padrões morfológicos relevantes para diferenciação entre benigno e maligno.

Variável	Importância
worst concave points	0,1445
worst area	0,1353
mean concave points	0,0983
worst radius	0,0968
mean radius	0,0682
worst perimeter	0,0661
mean perimeter	0,0652
mean concavity	0,0567
worst concavity	0,0460
mean area	0,0400




Figura 6 - Top 10 variáveis mais importantes no Random Forest.

8.3 Interpretação com SHAP

A técnica SHAP foi utilizada para complementar a explicação do modelo, mostrando a contribuição de cada variável nas predições. Essa abordagem permite observar, de forma global, quais atributos mais impactam a decisão do modelo e torna a solução mais transparente para análise técnica.




Figura 7 - Importância global das variáveis pela análise SHAP.

9. Extra: diagnóstico com imagens por CNN

Como entrega adicional, foi desenvolvido um experimento de Visão Computacional para classificação de imagens de mamografia. A base utilizada foi estruturada a partir do CBIS-DDSM, com imagens e arquivos clínicos de lesões do tipo massa e calcificação. O objetivo foi classificar os exames em benignos ou malignos utilizando uma CNN com transfer learning.

9.1 Base de imagens

Foram encontrados 6 arquivos CSV e 10.237 imagens no diretório do dataset. Após a associação entre metadados e imagens, a base final para treinamento da CNN ficou com 3.568 registros, contendo patient_id, pathology, target, tipo_lesao, origem_base e image_path_local.

Classe	Quantidade	Percentual
Benigno	2.111	59,16%
Maligno	1.457	40,84%
Total	3.568	100,00%

Tipo de lesão	Quantidade
Calcificação	1.872
Massa	1.696

Conjunto	Quantidade	Proporção aproximada
Treino	2.497	70%
Validação	535	15%
Teste	536	15%




Figura 8 - Exemplos de imagens de mamografia usadas no pipeline da CNN.

9.2 Pipeline e arquitetura

As imagens foram carregadas com TensorFlow, convertidas para RGB, redimensionadas para 224 x 224 pixels, organizadas em batches de 16 imagens e otimizadas com prefetch. Foi utilizado transfer learning com EfficientNetB0 pré-treinada na ImageNet, inicialmente congelada. A arquitetura incluiu camadas de data augmentation, pré-processamento da EfficientNet, GlobalAveragePooling2D, Dropout, camada densa intermediária e camada final sigmoide para classificação binária.

- Tamanho de entrada: 224 x 224 x 3.
- Batch size: 16.
- Data augmentation: horizontal flip, rotação, zoom e contraste.
- Função de perda: binary_crossentropy.
- Métricas: accuracy, precision, recall, AUC e F1-score calculado posteriormente.
- Class weights: benigno = 0,8453 e maligno = 1,2240 para reduzir impacto do desbalanceamento.

9.3 Treinamentos avaliados

Foram avaliadas três alternativas principais: modelo inicial com EfficientNetB0 congelada e class_weight, ajuste de threshold do modelo inicial, fine-tuning com class_weight e fine-tuning leve sem class_weight. A comparação final considerou principalmente o recall da classe maligna, por ser uma métrica crítica em cenários de triagem médica.

Modelo CNN	Accuracy / ROC-AUC	Métricas da classe maligno	Decisão
Inicial - EfficientNetB0 com class_weight	0,6399 / 0,6918	Precision: 0,5474 Recall: 0,6849 F1: 0,6085	Melhor opção para triagem
Fine-tuning com class_weight	0,6455 / 0,6948	Precision: 0,5560 Recall: 0,6667 F1: 0,6058	Maior acurácia, mas menor recall
Fine-tuning leve sem class_weight	0,6399 / 0,6929	Precision: 0,5722 Recall: 0,4703 F1: 0,5163	Descartado por baixo recall

O modelo inicial com `class_weight` foi considerado a melhor alternativa para triagem porque apresentou o maior recall para a classe maligna, identificando mais casos positivos. Apesar de o fine-tuning com `class_weight` ter apresentado maior accuracy e ROC-AUC, seu recall maligno ficou ligeiramente menor. Já o fine-tuning leve sem `class_weight` foi descartado por reduzir substancialmente o recall da classe maligna.




Figura 9 - Matriz de confusão da CNN no conjunto de teste.




Figura 10 - Curva ROC da CNN no conjunto de teste.

9.4 Interpretação dos resultados da CNN

Os resultados da CNN foram inferiores aos obtidos com os dados estruturados. Isso é esperado, pois imagens médicas exigem maior volume de dados, processamento especializado, padronização clínica e validação robusta. Mesmo assim, o experimento extra demonstrou uma arquitetura funcional de Visão Computacional, com pipeline de imagens, treinamento com GPU, transfer learning, class_weight, fine-tuning e análise de métricas.

Do ponto de vista clínico, o recall para maligno foi priorizado porque falsos negativos são especialmente sensíveis em triagem médica. Um modelo que deixa de sinalizar casos malignos pode atrasar a investigação médica. Portanto, para apoio inicial, a alternativa com maior recall maligno é mais adequada do que a alternativa com apenas maior accuracy.

10. Organização do projeto e reprodutibilidade

O projeto deve ser disponibilizado em um repositório GitHub com estrutura clara, permitindo que avaliadores acessem o código-fonte completo, notebooks, relatório, instruções de execução, dependências e Dockerfile.

```
tech-challenge-FIAP-fase1-diagnostico-medico/
├── README.md
├── requirements.txt
├── Dockerfile
├── notebooks/
│   ├── Tech_Challenge_Fase1_Diagnostico_Medico.ipynb
│   └── 02_extra_cnn_mamografia.ipynb
├── reports/
│   └── Relatorio_Tecnico_Tech_Challenge_Fase1_Diagnostico_Medico.pdf
├── images/
│   └── gráficos_e_resultados.png
└── src/
    └── scripts_auxiliares.py
```

10.1 README.md

O README.md deve apresentar a descrição do projeto, problema resolvido, bases utilizadas, tecnologias, estrutura de pastas, instruções de execução local, instruções com Docker, principais resultados, link do vídeo e integrantes.

10.2 requirements.txt

O arquivo requirements.txt deve conter as bibliotecas necessárias para reprodução do ambiente, incluindo:

```
pandas
numpy
matplotlib
seaborn
scikit-learn
xgboost
tensorflow
keras
opencv-python
```

```
pillow  
shap  
joblib  
jupyter  
notebook
```

10.3 Dockerfile

O Dockerfile deve permitir a criação de um ambiente reprodutível. Os comandos esperados para validação são:

```
docker build -t tech-challenge-fase1 .  
docker run -p 8888:8888 tech-challenge-fase1
```

11. Discussão crítica

O modelo estruturado apresentou desempenho elevado, mas os resultados devem ser interpretados com cautela. A base Breast Cancer Wisconsin é pública, limpa e controlada, o que pode produzir desempenho superior ao esperado em ambiente clínico real. Em produção, os dados podem conter ruídos, variações de origem, divergências de equipamento, registros incompletos e mudanças no perfil dos pacientes.

A solução é adequada como prova de conceito e ferramenta de apoio à triagem, mas não deve ser usada como diagnóstico autônomo. O uso prático exigiria validação externa, revisão médica, monitoramento contínuo, explicabilidade, governança de dados, segurança da informação e conformidade com normas de privacidade.

- O médico deve manter a palavra final sobre o diagnóstico.
- O modelo pode auxiliar na priorização e sinalização de casos suspeitos.
- Falsos negativos são mais críticos em cenários de triagem de câncer.
- A CNN precisa de validação mais robusta antes de qualquer uso clínico.
- É necessário avaliar vies, qualidade dos dados e generalização em bases reais.

12. Conclusão

O projeto atingiu o objetivo de construir uma solução inicial de IA para apoio ao diagnóstico médico. A abordagem principal com dados estruturados demonstrou alto desempenho usando Regressão Logística, com accuracy de 96,51%, recall de 96,30% e F1-score de 97,20% no conjunto de teste.

A etapa de interpretabilidade reforçou a transparência do modelo, permitindo identificar variáveis relevantes para a classificação. O Extra com CNN demonstrou conhecimento complementar em Visão Computacional, transfer learning, tratamento de imagens e avaliação crítica de métricas, destacando o modelo inicial com class_weight como melhor opção para triagem por apresentar maior recall para maligno.

Como próximos passos, recomenda-se validar a solução em bases clínicas externas, melhorar o pipeline de imagens, testar arquiteturas adicionais, aplicar validação cruzada, calibrar thresholds conforme o risco clínico e estruturar uma interface de apoio ao profissional de saúde.

13. Referências e links

- Dataset principal: Breast Cancer Wisconsin - disponível em scikit-learn e Kaggle.

- Dataset extra: CBIS-DDSM Breast Cancer Image Dataset - Kaggle.
- Repositório GitHub: <https://github.com/Diogosouza3101/tech-challenge-FIAP-fase1-diagnostico-medico>
- Vídeo de demonstração: <https://www.youtube.com/watch?v=8CTsa0KDnWw>
- Notebook principal: Tech_Challenge_Fase1_Diagnostico_Medico.ipynb.
- Notebook extra: 02_extra_cnn_mamografia.ipynb.