

TECH CHALLENGE - FASE 1

Sistema Inteligente de Suporte ao Diagnóstico Médico

Classificação de câncer de mama com Machine Learning e diagnóstico complementar por CNN

Campo	Informação
Curso	Pós IA para DEVs / FIAP
Fase	Fase 1
Tema	IA aplicada ao apoio diagnóstico médico
Integrantes	Diogo da Silva Souza
Repositório GitHub	https://github.com/Diogosouza3101/tech-challenge-FIAP-fase1-diagnostico-medico
Vídeo de demonstração	https://www.youtube.com/watch?v=g13xl9AW09A

Maio/2026

Resumo Executivo

Este relatório apresenta a solução desenvolvida para o Tech Challenge da Fase 1, cujo objetivo foi construir uma base inicial de Inteligência Artificial para apoio ao diagnóstico médico. A solução principal utiliza dados estruturados do dataset Breast Cancer Wisconsin para classificar exames como benignos ou malignos por meio de modelos de Machine Learning. Como entrega adicional, foi desenvolvido um experimento com imagens de mamografia usando redes neurais convolucionais e transfer learning.

No modelo principal, a Regressão Logística foi selecionada após comparação com Árvore de Decisão e Random Forest. No conjunto de teste, o modelo alcançou accuracy de 96,51%, recall de 96,30% e F1-score de 97,20%. No Extra com CNN, foram avaliadas arquiteturas como EfficientNetB0, DenseNet121, Xception, ensemble e pré-processamento com CLAHE. O modelo final selecionado foi a DenseNet121 com imagens de 320 x 320 pixels e threshold ajustado para 0,38, atingindo accuracy de 67,16%, recall maligno de 83,56%, F1-score maligno de 67,53% e ROC-AUC de 76,77%.

A proposta deve ser compreendida como ferramenta de apoio à triagem e à tomada de decisão clínica. O modelo não substitui a avaliação médica, devendo ser validado com dados reais e processos de governança antes de qualquer aplicação operacional.

Sumário

1. Introdução
2. Objetivo do projeto
3. Base de dados estruturada
4. Análise exploratória dos dados
5. Pré-processamento dos dados
6. Modelagem preditiva
7. Resultados do modelo principal
8. Interpretabilidade do modelo
9. Extra: diagnóstico com imagens por CNN
10. Organização do projeto e reprodutibilidade
11. Discussão crítica
12. Conclusão
13. Referências e links

1. Introdução

Hospitais e equipes clínicas lidam com um volume crescente de exames, imagens e informações assistenciais. Nesse contexto, soluções baseadas em Inteligência Artificial podem apoiar a análise inicial dos dados, acelerar etapas de triagem e destacar informações relevantes para o profissional de saúde.

Este projeto desenvolve uma solução inicial para suporte ao diagnóstico de câncer de mama, utilizando duas frentes complementares: uma abordagem principal com Machine Learning em dados estruturados e uma abordagem extra com Visão Computacional aplicada a imagens de mamografia. A classificação proposta distingue casos benignos e malignos, sempre considerando que a decisão final deve permanecer sob responsabilidade médica.

2. Objetivo do projeto

O objetivo deste trabalho é construir e avaliar modelos preditivos capazes de apoiar a classificação de exames médicos em benignos ou malignos, aplicando fundamentos de IA, Machine Learning, pré-processamento de dados, avaliação de métricas e interpretabilidade.

- Explorar e preparar uma base médica pública de dados estruturados.
- Treinar e comparar dois ou mais modelos de classificação.
- Avaliar o desempenho com métricas adequadas ao contexto médico.
- Interpretar os resultados por coeficientes, feature importance e SHAP.
- Desenvolver uma entrega extra com CNN para classificação de imagens de mamografia.
- Organizar o projeto para execução reproduzível via GitHub, README, requirements.txt e Dockerfile.

3. Base de dados estruturada

A base principal utilizada foi a Breast Cancer Wisconsin, disponível no scikit-learn e originalmente derivada de dados clínicos de câncer de mama. A base contém atributos numéricos extraídos de exames, como raio, textura, perímetro, área, suavidade, concavidade e pontos côncavos, incluindo suas versões médias, erros e piores valores.

A variável alvo foi representada da seguinte forma: 0 = maligno e 1 = benigno. A base final do notebook ficou com 569 registros e 32 colunas, sendo 30 variáveis explicativas, a variável target e uma coluna auxiliar de diagnóstico textual.

Classe	Quantidade	Percentual
Benigno	357	62,74%
Maligno	212	37,26%
Total	569	100,00%

4. Análise exploratória dos dados

A análise exploratória indicou que a base não possui valores nulos nas variáveis utilizadas, o que eliminou a necessidade de imputação. A distribuição das classes apresentou predominância de casos benignos, mas sem desbalanceamento extremo, permitindo o uso inicial das métricas accuracy, recall e F1-score.




Figura 1 - Distribuição dos diagnósticos na base estruturada.

A matriz de correlação mostrou forte associação entre alguns atributos, principalmente variáveis relacionadas a raio, perímetro, área, concavidade e pontos côncavos. Essa correlação sugere possível redundância entre atributos, mas os dados foram mantidos na etapa inicial porque os algoritmos avaliados conseguem lidar com esse comportamento e porque a interpretabilidade posterior permite identificar variáveis mais relevantes.




Figura 2 - Matriz de correlação das variáveis estruturadas.




Figura 3 - Correlação das variáveis com a variável target.

5. Pré-processamento dos dados

O pré-processamento consistiu na separação entre variáveis explicativas e variável alvo, divisão estratificada da base em treino, validação e teste, e padronização das variáveis numéricas. A padronização foi aplicada para colocar os atributos em escala comparável, etapa especialmente relevante para modelos sensíveis à magnitude das variáveis, como a Regressão Logística.

Conjunto	Quantidade de registros	Observação
Treino	397	Usado para ajuste dos modelos
Validação	86	Usado para comparação inicial
Teste	86	Usado para avaliação final

- Variáveis explicativas: 30 atributos numéricos do exame.
- Variável alvo: target, com 0 para maligno e 1 para benigno.

- Divisão com `random_state=42` e `stratify` para preservar a proporção das classes.
- Padronização com `StandardScaler` ajustado somente no conjunto de treino.

6. Modelagem preditiva

Foram treinados três modelos de classificação: Regressão Logística, Árvore de Decisão e Random Forest. A comparação inicial foi feita no conjunto de validação usando accuracy, recall e F1-score. Em contexto médico, o recall é uma métrica crítica, pois representa a capacidade do modelo de identificar corretamente os casos positivos. Como neste notebook a classe 1 representa benigno, a interpretação clínica das métricas deve ser complementada pela matriz de confusão e pelo classification report das duas classes.

Modelo	Accuracy validação	Recall validação	F1-score validação
Regressão Logística	1,0000	1,0000	1,0000
Random Forest	0,9651	0,9630	0,9720
Árvore de Decisão	0,9535	0,9444	0,9623

A Regressão Logística apresentou o melhor desempenho no conjunto de validação e foi selecionada para a avaliação final no conjunto de teste. Além do desempenho, esse modelo tem vantagem de maior interpretabilidade por meio da análise dos coeficientes.

7. Resultados do modelo principal

No conjunto de teste, a Regressão Logística manteve desempenho elevado, indicando boa capacidade de generalização para dados não vistos. O modelo apresentou apenas 3 erros de classificação em 86 registros avaliados.

Métrica	Resultado no teste
Accuracy	0,9651 / 96,51%
Recall	0,9630 / 96,30%
F1-score	0,9720 / 97,20%

Classe	Precision	Recall	F1-score	Support
Maligno (0)	0,94	0,97	0,95	32
Benigno (1)	0,98	0,96	0,97	54
Accuracy	-	-	0,97	86
Macro avg	0,96	0,97	0,96	86
Weighted avg	0,97	0,97	0,97	86




Figura 4 - Matriz de confusão da Regressão Logística no conjunto de teste.

8. Interpretabilidade do modelo

A interpretabilidade foi avaliada por três frentes: coeficientes da Regressão Logística, importância de variáveis do Random Forest e análise SHAP. Essa etapa é relevante porque modelos aplicados à saúde precisam de transparência e rastreabilidade, principalmente quando usados como apoio à decisão.

8.1 Coeficientes da Regressão Logística

Na Regressão Logística, coeficientes com maior valor absoluto indicam maior influência sobre a classificação. Coeficientes positivos favorecem a classe 1, enquanto coeficientes negativos favorecem a classe 0.

Variável	Coeficiente	Coef. absoluto
worst symmetry	-1,1022	1,1022
radius error	-1,0944	1,0944
worst texture	-1,0773	1,0773
worst area	-0,9277	0,9277
area error	-0,9211	0,9211
worst radius	-0,9113	0,9113
worst concavity	-0,8843	0,8843
worst smoothness	-0,8012	0,8012
worst concave points	-0,7804	0,7804
mean compactness	0,7343	0,7343




Figura 5 - Top 10 variáveis mais influentes na Regressão Logística.

8.2 Feature importance com Random Forest

Como visão complementar, a importância das variáveis foi avaliada com Random Forest. As variáveis mais importantes se concentraram em atributos relacionados a pontos côncavos, área, raio, perímetro e concavidade, coerentes com padrões morfológicos relevantes para diferenciação entre benigno e maligno.

Variável	Importância
worst concave points	0,1445
worst area	0,1353
mean concave points	0,0983
worst radius	0,0968
mean radius	0,0682
worst perimeter	0,0661
mean perimeter	0,0652
mean concavity	0,0567
worst concavity	0,0460
mean area	0,0400




Figura 6 - Top 10 variáveis mais importantes no Random Forest.

8.3 Interpretação com SHAP

A técnica SHAP foi utilizada para complementar a explicação do modelo, mostrando a contribuição de cada variável nas predições. Essa abordagem permite observar, de forma global, quais atributos mais impactam a decisão do modelo e torna a solução mais transparente para análise técnica.




Figura 7 - Importância global das variáveis pela análise SHAP.

9. Extra: diagnóstico com imagens por CNN

Como entrega adicional, foi desenvolvido um experimento de Visão Computacional para classificação de imagens de mamografia. A base utilizada foi estruturada a partir do CBIS-DDSM, contendo imagens e metadados clínicos de lesões do tipo massa e calcificação. O objetivo foi classificar os exames em benignos ou malignos por meio de redes neurais convolucionais com transfer learning.

Essa etapa complementa o modelo principal com dados estruturados e demonstra a aplicação de CNNs em imagens médicas. A abordagem foi tratada como prova de conceito para apoio à triagem, sem finalidade de substituir a avaliação médica.

9.1 Base de imagens

Foram encontrados 6 arquivos CSV e 10.237 imagens no diretório do dataset. Após a associação entre metadados clínicos e arquivos de imagem, a base final da CNN ficou com 3.568 registros, contendo patient_id, pathology, target, tipo_lesao, origem_base e image_path_local.

Classe	Quantidade	Percentual
Benigno	2.111	59,16%
Maligno	1.457	40,84%
Total	3.568	100,00%

Tipo de lesão	Quantidade
Calcificação	1.872
Massa	1.696

Conjunto	Quantidade	Proporção aproximada
Treino	2.497	70%
Validação	535	15%
Teste	536	15%




Figura 8 - Exemplos de imagens de mamografia usadas no pipeline da CNN.

9.2 Pipeline e arquitetura final

As imagens foram carregadas com TensorFlow, convertidas para RGB, redimensionadas e processadas de acordo com a arquitetura avaliada. A versão final utilizou a DenseNet121 pré-treinada na ImageNet, com entrada de 320 x 320 pixels e pré-processamento específico da DenseNet. O modelo foi avaliado com threshold ajustado para 0,38, priorizando maior sensibilidade para a classe maligna.

- Arquitetura final: DenseNet121 com transfer learning.
- Tamanho de entrada: 320 x 320 x 3.
- Função de perda: binary_crossentropy.
- Métricas avaliadas: accuracy, precision, recall, F1-score, matriz de confusão e ROC-AUC.
- Estratégias testadas: class_weight, fine-tuning, ajuste de threshold, Xception, ensemble e CLAHE.
- Critério de seleção: priorização do recall e F1-score da classe maligna, considerando o risco clínico de falsos negativos.

9.3 Experimentos avaliados

Foram testadas diferentes configurações de CNN com transfer learning. O objetivo foi comparar arquiteturas e estratégias de decisão, avaliando não apenas a acurácia, mas principalmente o recall da classe maligna, por se tratar de uma aplicação de triagem médica.

Modelo CNN	Accuracy / ROC-AUC	Métricas da classe maligna	Decisão
EfficientNetB0 com class_weight	0,6399 / 0,6918	Precision: 0,5474 Recall: 0,6849 F1: 0,6085	Baseline inicial
DenseNet121 320 x 320 - threshold 0,50	0,6922 / 0,7677	Precision: 0,6063 Recall: 0,7032 F1: 0,6512	Boa acurácia e bom ROC-AUC
DenseNet121 320 x 320 - threshold 0,38	0,6716 / 0,7677	Precision: 0,5666 Recall: 0,8356 F1: 0,6753	Modelo final selecionado
Xception 299 x 299 - threshold 0,50	0,7034 / 0,7650	Precision: 0,6351 Recall: 0,6438 F1: 0,6395	Maior acurácia, mas menor recall maligno
Ensemble DenseNet + Xception	0,4085 / 0,5528	Recall muito alto, porém baixa acurácia e baixo ROC-AUC	Descartado
DenseNet121 + CLAHE	0,4160 / 0,6009	Recall alto, porém baixa capacidade discriminativa	Descartado

O Xception apresentou a maior acurácia geral, porém o DenseNet121 com threshold ajustado para 0,38 apresentou o melhor equilíbrio clínico, principalmente pelo recall de 83,56% para a classe maligna. O experimento com CLAHE foi descartado porque reduziu o ROC-AUC e tornou o modelo excessivamente enviesado para a classe maligna.

9.4 Resultado final da CNN

O modelo final selecionado foi a DenseNet121 com imagens em 320 x 320 pixels e threshold ajustado em 0,38. Essa configuração foi escolhida porque reduziu o número de falsos negativos em relação às demais alternativas, mesmo sem apresentar a maior acurácia geral.

Métrica	Resultado no teste
Accuracy	0,6716 / 67,16%
Precision da classe maligna	0,5666 / 56,66%
Recall da classe maligna	0,8356 / 83,56%
F1-score da classe maligna	0,6753 / 67,53%
ROC-AUC	0,7677 / 76,77%

Matriz de confusão	Predito Benigno	Predito Maligno
Real Benigno	177	140
Real Maligno	36	183

A matriz de confusão mostra que, dos 219 casos malignos do conjunto de teste, o modelo identificou corretamente 183 casos e classificou 36 como benignos. O recall maligno de 83,56% indica boa sensibilidade para uma proposta de apoio à triagem.




Figura 9 - Matriz de confusão da CNN DenseNet121 no conjunto de teste.




Figura 10 - Curva ROC da CNN DenseNet121 no conjunto de teste.

9.5 Interpretação dos resultados da CNN

Os resultados da CNN foram inferiores aos obtidos com os dados estruturados, o que é esperado em imagens médicas, pois esse tipo de dado exige maior volume de amostras, padronização clínica, controle de qualidade das imagens, validação externa e processamento especializado. Ainda assim, o experimento demonstrou uma arquitetura funcional de Visão Computacional, com pipeline de imagens, transfer learning, ajuste de threshold e análise crítica de métricas.

Do ponto de vista clínico, a escolha do modelo final priorizou o recall da classe maligna. Em triagem de câncer de mama, falsos negativos são mais críticos do que falsos positivos, pois uma imagem maligna classificada como benigna pode atrasar a investigação médica. Por esse motivo, o DenseNet121 com threshold 0,38 foi considerado mais adequado do que o Xception, apesar de este ter apresentado maior acurácia geral.

O modelo não deve ser utilizado como diagnóstico definitivo. Seu papel é sinalizar casos suspeitos e apoiar a priorização da análise médica. A aplicação prática exigiria validação com especialistas, testes em bases externas, calibração clínica do threshold, governança de dados e monitoramento contínuo de desempenho.

10. Organização do projeto e reprodutibilidade

O projeto deve ser disponibilizado em um repositório GitHub com estrutura clara, permitindo que avaliadores acessem o código-fonte completo, notebooks, relatório, instruções de execução, dependências e Dockerfile.

```
tech-challenge-FIAP-fase1-diagnostico-medico/
├── README.md
├── requirements.txt
├── Dockerfile
├── notebooks/
│   ├── Tech_Challenge_Fase1_Diagnostico_Medico.ipynb
│   └── 04_extra_cnn_mamografia_versao_final.ipynb
├── reports/
│   └── Relatorio_Tecnico_Tech_Challenge_Fase1_Diagnostico_Medico.pdf
├── images/
│   └── gráficos_e_resultados.png
└── src/
    └── scripts_auxiliares.py
```

10.1 README.md

O README.md deve apresentar a descrição do projeto, problema resolvido, bases utilizadas, tecnologias, estrutura de pastas, instruções de execução local, instruções com Docker, principais resultados, link do vídeo e integrantes.

10.2 requirements.txt

O arquivo requirements.txt deve conter as bibliotecas necessárias para reprodução do ambiente, incluindo:

```
pandas
numpy
matplotlib
seaborn
```

```
scikit-learn  
xgboost  
tensorflow  
keras  
opencv-python  
pillow  
shap  
joblib  
jupyter  
notebook
```

10.3 Dockerfile

O Dockerfile deve permitir a criação de um ambiente reprodutível. Os comandos esperados para validação são:

```
docker build -t tech-challenge-fase1 .  
docker run -p 8888:8888 tech-challenge-fase1
```

11. Discussão crítica

O modelo estruturado apresentou desempenho elevado, mas os resultados devem ser interpretados com cautela. A base Breast Cancer Wisconsin é pública, limpa e controlada, o que pode produzir desempenho superior ao esperado em ambiente clínico real. Em produção, os dados podem conter ruídos, variações de origem, divergências de equipamento, registros incompletos e mudanças no perfil dos pacientes.

A solução é adequada como prova de conceito e ferramenta de apoio à triagem, mas não deve ser usada como diagnóstico autônomo. O uso prático exigiria validação externa, revisão médica, monitoramento contínuo, explicabilidade, governança de dados, segurança da informação e conformidade com normas de privacidade.

- O médico deve manter a palavra final sobre o diagnóstico.
- O modelo pode auxiliar na priorização e sinalização de casos suspeitos.
- Falsos negativos são mais críticos em cenários de triagem de câncer.
- A CNN precisa de validação mais robusta antes de qualquer uso clínico.
- É necessário avaliar viés, qualidade dos dados e generalização em bases reais.

12. Conclusão

O projeto atingiu o objetivo de construir uma solução inicial de IA para apoio ao diagnóstico médico. A abordagem principal com dados estruturados demonstrou alto desempenho usando Regressão Logística, com accuracy de 96,51%, recall de 96,30% e F1-score de 97,20% no conjunto de teste.

A etapa de interpretabilidade reforçou a transparência do modelo estruturado, permitindo identificar variáveis relevantes para a classificação. O Extra com CNN demonstrou conhecimento complementar em Visão Computacional, transfer learning, tratamento de imagens e avaliação crítica de métricas. Após os experimentos, a configuração final selecionada foi a DenseNet121 com threshold ajustado para 0,38, por apresentar melhor equilíbrio clínico, especialmente pelo recall de 83,56% para a classe maligna.

Como próximos passos, recomenda-se validar a solução em bases clínicas externas, melhorar o pipeline de imagens, testar arquiteturas adicionais, aplicar validação cruzada, calibrar thresholds conforme o risco clínico e estruturar uma interface de apoio ao profissional de saúde.

13. Referências e links

- Dataset principal: Breast Cancer Wisconsin - disponível em scikit-learn e Kaggle.
- Dataset extra: CBIS-DDSM Breast Cancer Image Dataset - Kaggle.
- Repositório GitHub: <https://github.com/Diogosouza3101/tech-challenge-FIAP-fase1-diagnostico-medico>
- Vídeo de demonstração: <https://www.youtube.com/watch?v=g13xI9AW09A>
- Notebook principal: Tech_Challenge_Fase1_Diagnostico_Medico.ipynb.
- Notebook extra: 04_extra_cnn_mamografia-versao_final.ipynb.